

Сравнение моделей для детекции аномалий в 223-ФЗ

ВКР: Detection of Anomalies and Unfair Competition in Commercial Tenders Using NLP

Полина Рыльцева, ФЭН НИУ ВШЭ. Корпус: 400 лотов, 224 manually-annotated флага.

Модель	Spec*	Flags**	Precision†	Cost‡	Time/lot	Заметки
v1 baseline	5%	91	~13%	\$2.5	8s	gpt-4o-mini, codebook v1 (EU/OECD)
v3+2stage	5%	88	~15%	\$5	30s	+ whitelist W1-W15 + 2-stage
Rule detector	75%	6	100% (6/6)	\$0	1s	5 regex-правил, deterministic
Ensemble v2∩v3	95%	1	28.6% (на 30 lots)	\$10	60s	пересечение LLM-пайплайнов
gpt-5.5 zero-shot	n/a	4 (signal)	100% (4/4)	\$80	30s	frontier, дорого
FT v1 (gpt-4.1)	80%	5	60% strict / 100% loose	\$5	5s	122 ex, val loss 0.17
FT v2 (gpt-4.1)	65%	8	87.5% (7/8)	\$5	5s	204 ex, val loss 0.03

*Specificity — % правильно идентифицированных «чистых» лотов на 20 held-out лотах не из training.

**Flags — общее число флагов на тех же 20 held-out лотах. Меньше = меньше шума.

†Precision — strict (только TRUE) на held-out, manually verified для FT v1, FT v2, Rule detector. Для v1/v3+2s оценка экстраполирована с 121-flag manual review (см. docs/results.md).

‡Cost — стоимость анализа 200 лотов в USD. Inference + (для FT) разовая тренировка.

Описания моделей:

- **v1 baseline** — стартовая prompt-engineered модель на gpt-4o-mini. Codebook v1 — таксономия 8 меток на основе EU Directive 2014/24/EU и OECD Bid-Rigging Indicators. Помечает почти все 223-ФЗ лоты как HIGH из-за обязательных формальных норм закона. *Главный научный результат: показала, что наивный перенос EU/OECD codebook на 223-ФЗ не работает.*
- **v3+2stage** — prompt-engineering iteration: codebook расширен whitelist'ом W1-W15 (15 категорий стандартных норм 223-ФЗ, которые НЕ нужно флагать). Добавлен второй LLM-вызов для валидации каждого флага. Чуть лучше дискриминирует, но всё ещё over-flags на новых данных.
- **Rule detector** — 5 regex-правил (R1: «Не предусмотрено» в критериях; R3: прямой бан «или эквивалент»; и др.). **Manually verified: 100% strict precision** (6/6 флагов TRUE на held-out). Дешёвый pre-filter, но узкое покрытие паттернов.
- **Ensemble v2∩v3** — пересечение флагов из двух LLM-пайплайнов через fuzzy span matching. Самая консервативная модель: 28.6% strict precision (manual), но recall очень низкий (7 флагов на 30 лотов).
- **gpt-5.5 zero-shot** — frontier модель OpenAI (release 2026-04-23). 100% lot-level precision на signal subset (4 из 4 — TRUE), но \$80/200 лотов делает её **нерентабельной для production** (1000+ лотов/день).
- **FT v1** — зафайнтюенная gpt-4.1 на 122 manually-annotated examples. 80% specificity на held-out, **manually verified: 60% strict / 100% loose precision** (3 TRUE + 2 PARTIAL из 5 флагов). PARTIAL флаги — compatibility-justified brand (W7): закупка ремонта оборудования конкретного производителя НПП «ЭПРО».
- **FT v2** — та же база (gpt-4.1), но обучена на расширенном датасете 204 examples с балансом 46% positive (vs v1 14%). Источники: 121 v1-разметка + 74 manual review held-out + 78 rule-based silver labels (R1+R3) + 7 ensemble verdicts + 4 gpt-5.5 silver. Validation loss 0.03 (5× лучше v1). **Manual verified: 87.5% strict precision** (7/8 флагов TRUE на held-out). Единственный FP — модель неправильно интерпретировала «*» или эквивалент как нарушение, тогда как это корректное обозначение в TZ. **Demonstrated transfer learning:** сгенерализовала R3 паттерн на 5 новых лотов. **Самая сильная модель в линейке.**

Production cascade architecture:

$Lot \rightarrow Ruledetector(free) \rightarrow FTv2(\$5/200) \rightarrow Humanreview(topflagged)$

$Cost : \sim \$0.025/, throughput : \sim 12/, scalable 17K/APIkey.$